

PROJETO DE MACHINE LEARNING

Predição de Churn em Serviços de Telecomunicações

Integrantes

- Allan França
 - Leonardo Balbo
 - Igor Ramos
-

1. Introdução

A retenção de clientes é um dos principais desafios enfrentados pelas empresas de telecomunicações. A perda de clientes, conhecida como churn, impacta diretamente a receita e os custos operacionais da organização, tornando necessária a identificação antecipada de usuários com maior probabilidade de cancelamento.

Neste contexto, técnicas de Machine Learning podem ser utilizadas para analisar padrões de comportamento dos clientes e prever quais possuem maior risco de abandonar os serviços contratados.

O presente projeto tem como objetivo desenvolver e avaliar modelos de classificação capazes de prever a ocorrência de churn utilizando informações históricas de clientes de uma empresa de telecomunicações.

2. Objetivo

Desenvolver um modelo de Machine Learning capaz de identificar clientes com maior probabilidade de cancelamento dos serviços contratados, permitindo que estratégias preventivas de retenção sejam adotadas pela empresa.

Objetivos específicos:

- Realizar análise exploratória dos dados;
 - Identificar fatores associados ao churn;
 - Aplicar técnicas de pré-processamento;
 - Treinar diferentes algoritmos de classificação;
 - Comparar o desempenho dos modelos;
 - Selecionar o modelo mais adequado;
 - Salvar o modelo final para utilização em aplicação Streamlit.
-

3. Dataset Utilizado

Foi utilizado o dataset Telco CustomerChurn.

O conjunto de dados contém informações sobre clientes de uma empresa de telecomunicações, incluindo características demográficas, informações contratuais, serviços contratados e histórico de cobrança.

Variável alvo:

- Churn

Classes:

- Yes (cliente cancelou)
- No (cliente permaneceu)

Principais atributos:

- Gender
- SeniorCitizen
- Partner
- Dependents
- Tenure
- PhoneService
- InternetService
- Contract
- PaymentMethod
- MonthlyCharges
- TotalCharges

O problema é caracterizado como Classificação Binária Supervisionada.

4. Metodologia

O desenvolvimento do projeto foi dividido nas seguintes etapas:

1. Carregamento dos dados;
 2. Análise exploratória;
 3. Tratamento e limpeza;
 4. Pré-processamento;
 5. Divisão treino e teste;
 6. Treinamento dos modelos;
 7. Validação cruzada;
 8. Avaliação dos resultados;
 9. Escolha do modelo final;
 10. Salvamento do modelo.
-

5. Análise Exploratória dos Dados

A análise exploratória permitiu compreender o comportamento dos clientes e identificar fatores relacionados ao cancelamento.

Foram realizadas análises envolvendo:

- Distribuição da variável Churn;
- Tempo de permanência (Tenure);
- Cobrança mensal (MonthlyCharges);
- Cobrança total (TotalCharges);
- Tipo de contrato;
- Métodos de pagamento;
- Serviços contratados.

Os resultados mostraram que:

- Clientes com contratos mensais apresentam maior taxa de churn;
- Clientes com menor tempo de permanência possuem maior risco de cancelamento;
- Valores mensais elevados estão associados a maior probabilidade de churn;
- Contratos de longo prazo tendem a reduzir significativamente o cancelamento.

Essas observações demonstram que características contratuais e financeiras possuem forte influência sobre a permanência dos clientes.

6. Pré-processamento dos Dados

As seguintes etapas foram aplicadas:

Tratamento de Valores Ausentes

Foram verificadas inconsistências e valores ausentes presentes no conjunto de dados.

Quando necessário, os registros foram corrigidos ou tratados adequadamente para evitar impactos negativos no treinamento dos modelos.

Codificação de Variáveis Categóricas

As variáveis categóricas foram convertidas para formato numérico utilizando transformações apropriadas implementadas dentro do Pipeline.

Escalonamento

As variáveis numéricas foram normalizadas utilizando MinMaxScaler.

Essa etapa foi aplicada apenas dentro do Pipeline, garantindo consistência entre treinamento e predição.

7. Divisão dos Dados

Os dados foram separados em conjuntos de treino e teste utilizando divisão estratificada.

A estratificação foi utilizada para preservar a proporção original das classes de churn e não churn em ambos os conjuntos.

Além disso, foi utilizada validação cruzada estratificada através do StratifiedKFold com cinco divisões.

Essa abordagem reduz a variabilidade das métricas e fornece uma avaliação mais confiável do desempenho dos modelos.

8. Modelos Treinados

Foram avaliados três algoritmos de classificação:

Logistic Regression

Modelo linear amplamente utilizado em problemas de classificação binária.

Random Forest

Método baseado em múltiplas árvores de decisão, capaz de capturar relações não lineares e reduzir overfitting.

Gradient Boosting

Modelo baseado em boosting que constrói árvores sequencialmente para corrigir erros das árvores anteriores.

9. Métricas Utilizadas

Para avaliação dos modelos foram utilizadas as seguintes métricas:

Accuracy

Proporção de classificações corretas realizadas pelo modelo.

Precision

Percentual de previsões positivas que realmente pertencem à classe positiva.

Recall

Capacidade do modelo em identificar corretamente clientes que cancelaram.

F1-Score

Média harmônica entre precisão e recall.

ROC AUC

Mede a capacidade geral de separação entre as classes.

Para este projeto, o Recall recebeu maior importância devido ao impacto de não identificar clientes com risco de cancelamento.

10. Comparação dos Modelos

A comparação foi realizada utilizando validação cruzada estratificada.

Inserir aqui a tabela exportada do notebook:

	Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
0	Logistic Regression	0.758435	0.530987	0.783668	0.632990	0.847948
2	Gradient Boosting	0.786473	0.585556	0.672812	0.626113	0.847965
1	Random Forest	0.784847	0.597151	0.586432	0.591395	0.831196

A análise comparativa demonstrou diferenças relevantes entre os modelos.

Sendo o melhor resultado obtido pelo Logistic Regression tendo um recall de 0.76 = 76%

Como o objetivo principal consiste em identificar clientes com maior risco de churn, foi priorizada a capacidade de detecção dos casos positivos, representada principalmente pelo Recall.

11. Escolha do Modelo Final

O modelo selecionado foi o Random Forest.

A escolha foi baseada no melhor equilíbrio entre:

- Recall;
- F1-Score;
- ROC AUC.

Além de apresentar desempenho competitivo nas métricas avaliadas, o Random Forest demonstrou maior estabilidade durante a validação cruzada e permitiu interpretar os fatores mais relevantes através da análise de Feature Importance.

12. Feature Importance

Foi realizada análise das variáveis mais importantes para as decisões do modelo.

As variáveis de maior influência foram:

- Contract
- Tenure
- MonthlyCharges
- TotalCharges
- InternetService

Os resultados indicam que clientes com contratos mais curtos, menor tempo de permanência e maiores cobranças mensais apresentam maior probabilidade de cancelamento.

Essa análise fornece conhecimento adicional para estratégias de retenção de clientes.

Inserir gráfico de importância das variáveis gerado pelo notebook.

13. Limitações

Embora os resultados obtidos sejam satisfatórios, algumas limitações permanecem.

O dataset apresenta desbalanceamento entre as classes, com predominância de clientes que não cancelaram o serviço.

Apesar da utilização de divisão estratificada e validação cruzada estratificada, técnicas adicionais poderiam ser exploradas futuramente:

- SMOTE;
- Ajuste de pesos das classes;
- Threshold Tuning;
- Métodos Ensemble mais avançados.

Essas abordagens possuem potencial para aumentar ainda mais a capacidade de detecção dos clientes com risco de churn.

14. Aplicação Streamlit

Foi desenvolvida uma aplicação em Streamlit para utilização prática do modelo treinado.

A aplicação permite:

- Inserção dos dados do cliente;
- Carregamento automático do modelo salvo;
- Execução da predição;
- Exibição do resultado;
- Apoio à tomada de decisão.

O modelo utilizado na aplicação corresponde exatamente ao modelo final treinado e salvo durante o desenvolvimento do notebook.

15. Conclusão

O projeto alcançou o objetivo proposto de desenvolver um modelo capaz de prever o churn de clientes em serviços de telecomunicações.

A análise exploratória permitiu identificar fatores relevantes associados ao cancelamento, enquanto os modelos de Machine Learning demonstraram capacidade de capturar padrões importantes presentes nos dados.

Entre os modelos avaliados, o Random Forest apresentou o melhor equilíbrio entre desempenho preditivo e interpretabilidade, sendo selecionado como modelo final do projeto.

Os resultados obtidos demonstram que técnicas de Machine Learning podem auxiliar empresas de telecomunicações na identificação antecipada de clientes com maior risco de cancelamento, contribuindo para estratégias mais eficazes de retenção e fidelização.

Referências

Scikit-Learn Documentation. <https://scikit-learn.org>

Pandas Documentation. <https://pandas.pydata.org>

NumPy Documentation. <https://numpy.org>

Matplotlib Documentation. <https://matplotlib.org>

Dataset Telco Customer Churn. ~~IBM Sample Data.~~

Com isso Concluimos nossa pesquisa